TXT-Sammeldateien in einzelne Entscheidungen trennen und benennen

Sowohl die zur Trennung eingesetzte Zeichenkette als auch die Orte, an denen man Entscheidungsdatum und Aktenzeichen findet, unterscheiden sich, je nachdem, welche Datenquelle man verwendet. Das Skript geht davon aus, dass Batch-Dateien vorliegen, die mehrere Entscheidungen enthalten, deren Anzahl sich aus dem Dateinamen (z.B. '0000-0400.txt') ermitteln lässt.

```
In [ ]:
sourcepath = # Pfad zum Ordner, in dem die TXT-Sammeldateien liegen
targetpath = # Pfad zum Ordner, in den die einzelnen Entscheidungen gelegt werden se
```

```
In [ ]:
```

```
import re, string, os
```

In []:

```
def txtsplit(collectionfile, number_of_decisions, output_path):
    """Receives a collectionfile with number of decisions different decisions,
       splits it into individual decisions, and writes the files to output_path."""
    splitter = # Zeichenkette, an welcher der Übergang zwischen Entscheidungen erkei
    with open(collectionfile, "r") as f:
        text = f.read()
    files = text.split(f"{splitter}")[:-1]
    # [:-1] ggf. entfernen, falls Splitter nicht Symbol am Ende jeder Entscheidung
    assert len(files) == number of decisions
    filenames = {f[:-4] for f in os.listdir(output path) if f.endswith('.txt')}
    letters = string.ascii lowercase
    new filenames = set()
    # Suchmethoden für Datum und Aktenzeichen ggf. anpassen
    for text in files:
        raw date = re.search("(?<=Entscheidungsdatum:.).*?\d{4}(?=\s)", text, re.DO
        file date = f''{raw date[-1]}-{raw date[-2]}-{raw date[0][-2:]}
        raw_az = re.search("(?<=Aktenzeichen:).*?(XI.*?/\d{2})", text, re.DOTALL).gu</pre>
        file az = raw az.replace("/", "-")
        original filename = f"{file date} {file az}"
        # Eindeutige Dateinamen sicherstellen
        filename = original filename
        idx = 0
        while filename in filenames:
            filename = f"{original filename} {letters[idx]}"
            idx += 1
        filenames.add(filename)
        new filenames.add(filename)
        with open(f"{output_path}/{filename}.txt", "w") as f:
            f.write(text)
    assert len(new filenames) == len(files)
```

```
In [ ]:
```

```
for f in os.listdir(sourcepath):
   number_of_decisions = int(f[:-4][-4:])-int(f[:4])+1
   txtsplit(f'{sourcepath}/{f}', number_of_decisions, targetpath)
```

Ende.